



گزارش کار آزمایشگاه شماره ۳

مقدمه: از طراحی مفهومی تا استقرار عملیاتی

همان‌طور که در سناریوی تمرین سوم درس به خاطر دارید، ما گذاری چالش‌برانگیز از محیط‌های کنترل‌شده رباتیک به سوی پردازش تصاویر واقعی در جراحی بالینی آب‌مروارید داشتیم. در آن تمرین، تمرکز بر روی مفاهیم نظری، انتخاب استراتژی‌ها و معماری سیستم ادراک بصری بود. اکنون در این گزارش کار آزمایشگاه، شما در جایگاه یک مهندس هوش مصنوعی در تیم توسعه‌دهنده یک پلتفرم دستیار جراح قرار دارید.

هدف این آزمایشگاه، کدنویسی، پیاده‌سازی عملیاتی و ارزیابی تجربی (Empirical Validation) تکنیک‌هایی است که در نوتبوک جامع CNN فرا گرفته‌اید. در اینجا تئوری کافی نیست؛ خروجی شما باید شامل کدهای ماژولار پای‌تورچ (PyTorch)، نتایج پروفایلینگ زمان‌بندی و تحلیل‌های عمیق از رفتار شبکه در مواجهه با خطاهای دنیای واقعی باشد.

۱ ماموریت اول: کدنویسی خط لوله داده (Data Pipeline) و پیاده‌سازی افزونگی‌های نوین

در محیط آزمایشگاه و پروژه‌های واقعی، استفاده از دیتاست‌های آماده و ماژول‌های ازپیش‌نوشته‌شده پاسخگو نیست. شما باید جریان داده خود را برای یک مسئله Multi-label با دقت کنترل کنید:

آ. توسعه Dataset و DataLoader سفارشی: یک کلاس CustomDataset در پای‌تورچ کدنویسی کنید که تصاویر جراحی و برچسب‌های چندگانه (به صورت Multi-hot encoding) را از روی فایل‌های متادیتای دیتاست بخواند. کلاس شما باید قابلیت دریافت و اعمال تبدیل‌های (Transforms) پیش‌پردازش را داشته باشد. سپس یک DataLoader بهینه بسازید و تاثیر استفاده از `pin_memory=True` و مقادیر مختلف `num_workers` را بر روی سرعت بارگذاری Batch‌ها در یک حلقه آزمایشی (بدون آموزش) اندازه‌گیری و مقایسه کنید.

ب. کدنویسی Mixup یا CutMix در حلقه آموزش: با ارجاع به بخش ۸ نوتبوک، یکی از تکنیک‌های Mixup یا CutMix را به صورت عملی درون حلقه آموزش (Training Loop) خود پیاده‌سازی کنید. قطعه کدی بنویسید که نشان دهد چگونه برچسب‌های Multi-label متناسب با نسبت ترکیب تصاویر، نرم (Interpolate) می‌شوند. همچنین نحوه اعمال تغییرات لازم در تابع زیان (مانند BCEWithLogitsLoss) برای پذیرش این برچسب‌های جدید را کدنویسی کرده و منطق ریاضی آن را در گزارش خود شرح دهید.

۲ ماموریت دوم: پروفایلینگ استنتاج (Inference Benchmarking) برای کنترل بلادرنگ

یک بازوی رباتیک همکار جراح، برای واکنش به موقع نیازمند پردازش بلادرنگ با کمترین تاخیر (Latency) است (بخش ۲۳ نوتبوک). مدل شما هرچقدر هم که دقیق باشد، اگر نتواند با نرخ فریم دوربین میکروسکوپ همگام شود، در اتاق عمل کاربردی نخواهد داشت:

آ. آموزش و مقایسه مدل‌های لبه (Edge) و سنگین: دو معماری متفاوت از نوتبوک انتخاب کنید: یک مدل سبک و مناسب برای سخت‌افزارهای محدود (مانند MobileNetV3 یا EfficientNet-B0) و یک مدل با ظرفیت

بالا (مانند ResNet50 یا ConvNeXt). هر دو مدل را با استفاده از Transfer Learning روی دیتاست جراحی آموزش دهید تا به همگرایی برسند.

ب. **محک‌زنی سرعت و حافظه (Benchmarking):** یک اسکریپت پروفایلینگ بنویسید که سه پارامتر اساسی را برای هر دو مدل روی داده‌آزمون (Test Set) روی سخت‌افزار GPU محاسبه کند:

- زمان استنتاج (Inference Time به میلی‌ثانیه)
- توان عملیاتی (Throughput بر حسب فریم بر ثانیه یا FPS)
- میزان حافظه مصرفی VRAM (در زمان استنتاج).

با توجه به نتایج، تحلیل کنید که آیا استفاده از مدل سنگین‌تر، ارزش افت سرعت در حلقه‌کنترلی ربات را دارد؟

ج. **پایه‌سازی Model Soups:** برای افزایش دقت مدل سبک‌تر بدون تحمیل بار محاسباتی اضافی در زمان استنتاج، تکنیک Model Soups (میانگین‌گیری وزن‌های ذخیره‌شده در چندین Checkpoint متوالی از یک مدل) را برنامه‌نویسی کنید. نشان دهید که این روش نسبت به رویکرد سنتی Ensemble Learning چه مزیت کینماتیکی (از نظر سرعت پردازش) ایجاد می‌کند.

۳ ماموریت سوم: دیباگ بصری شبکه و کالبدشکافی شکست‌ها (Failure Analysis)

مدل‌های یادگیری عمیق در کاربردهای حساس پزشکی نباید به‌صورت یک جعبه سیاه (Black-box) رها شوند. شما باید بتوانید دلیل خطاهای مدل خود را با استفاده از کدهای تفسیرپذیری (بخش‌های ۲۱ و ۲۲ نوت‌بوک) به‌صورت مستدل اثبات کنید:

آ. **کدنویسی و نگاشت فضای ویژگی با t-SNE:** کدی بنویسید که بردار ویژگی‌های استخراج‌شده (Embeddings) توسط لایه ماقبل آخر شبکه را برای کل داده‌های آزمون استخراج کند. سپس با استفاده از الگوریتم t-SNE این بردارها را به یک فضای دوبعدی نگاشت کنید. خوشه‌ها را بر اساس حضور ابزارهای کلیدی رنگ‌آمیزی کنید. آیا نمونه‌هایی وجود دارند که در فضای ویژگی در هم تنیده شده باشند؟ این درهم‌تنیدگی را چگونه تفسیر می‌کنید؟

ب. **تحلیل خطا با Grad-CAM:** اسکریپت ارزیابی خود را طوری توسعه دهید که به‌صورت خودکار ۵ نمونه False Positive (تشخیص اشتباه ابزاری که در تصویر حضور ندارد) و ۵ نمونه False Negative (عدم تشخیص ابزاری که در صحنه حاضر است) را فیلتر و ذخیره کند.

کد Grad-CAM را روی این تصاویر شکست‌خورده اعمال کنید و نقشه‌های حرارتی (Heatmaps) را در کنار تصاویر اصلی رسم نمایید. با بررسی نتایج بصری گزارش دهید که شبکه در زمان ارتکاب این خطاها، دقیقاً به کدام نواحی تصویر خیره شده بود؟ (آیا شبکه توسط انعکاس نور، دست جراح، یا بافت زمینه‌ای مشابه دچار خطای محاسباتی شده است؟)