



دانشگاه صنعتی خواجه نصیرالدین طوسی
دانشکده مهندسی برق

درس رباتیک و بینایی ماشین

استاد: دکتر حمیدرضا تقی راد

استاد: دکتر محمدجواد احمدی

آزمون میانترم

نام و نام خانوادگی	محمدامین محمدیون شبستری
شماره دانشجویی	۴۰۱۲۲۵۰۳
تاریخ	۱۴۰۵ خرداد



۱ سوال ۰

40122503

سوال ۴ ← آئینی دہری

آئینہ سار روز دہشت کے مہ باہان میری رشتہ دہی قرار ہے یہی مل کر سب کو اپنے ہتھ ہے لکھ دے دی
ہر انجا اپنے ہمارے ہتھ ہے !

دستریفت کی رو بروی پی حد اما از کجا نریخته؟ در صورتی که با ترکیب یکیم در این کار
به سبب از حد ادویه ای که در این کار است. این عمل است تو قبل ما

وین برائے loss (خام) $\rightarrow$ loss (معالجہ شدہ) $\rightarrow$ loss (معالجہ شدہ) $\rightarrow$ loss (معالجہ شدہ)

یعنی اس کی کہ انشاء پر ~~میں~~ تاخیر جس میں سبب غرضہ ہے بعد ازین سبب نکد در اطلاع حکم

این رتبه ها فراگیرند که بر ویلیس ها

مثال کا کجانی سادہ یہ تھی براقیت دارہ ؟ مایہ نجا کہ تیر فر فر کریم کہ ادمش کند بود کہ نیاز آید
بہ کہوں این فضا یک ہی فلی واہ ماہادہ وں مٹی یا اتر ماہ ہزاراں تابہ جی ؟
مثلاً ہزاراں بخواں ۱۰۱ بدل خودت متانت درے کلیم کہ مکر کریم اودیہاں خاں فوج دارہ ؟
زمن مایہ نوہ رو باہ ہزاراں کہہ دیسے کہتے سے فضلی مار جیکے مہائی نہ دارم بیار سترہ مے وہ بیرون ما
ہا اتر تال تنظم رہے ماری نیاز دایم

[illegible]

شکل ۱

سوال ۱

الف) رابطه کلی ماتریس تبدیل دوربین به پایه (0T_C)

با توجه به ویژگی ضرب زنجیره‌ای ماتریس‌های تبدیل همگن، رابطه کلی به صورت زیر است:

$${}^0T_C = {}^0T_E \cdot {}^ET_C \quad (۱)$$

ماتریس ET_C بر اساس دوران 90° حول محور X و انتقال $d = [0, 0, 5]^T$ به شکل زیر تشکیل می‌شود:

$${}^ET_C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & \cos(90^\circ) & -\sin(90^\circ) & 0 \\ 0 & \sin(90^\circ) & \cos(90^\circ) & 5 \\ 0 & 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 5 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (۲)$$

رابطه نهایی کالیبراسیون:

$${}^0T_C = {}^0T_E \cdot \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 5 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (۳)$$

ب) مراحل محاسباتی و فرمول ساختار ضرب برای یافتن 0P

ابتدا بردار مختصات شیء در قاب دوربین (${}^CP = [1, 10, -1, 2]^T$) را با افزودن درایه ۱ به فرم همگن در می‌آوریم:

$${}^CP_{homogeneous} = \begin{bmatrix} 1 \\ 10 \\ -1 \\ 2 \\ 1 \end{bmatrix} \quad (۴)$$

فرمول ساختار زنجیره‌ای ضرب ماتریس‌ها برای انتقال مختصات به قاب پایه (0P) به صورت زیر است:

$${}^0P_{homogeneous} = {}^0T_C \cdot {}^CP_{homogeneous} = {}^0T_E \cdot {}^ET_C \cdot {}^CP_{homogeneous} \quad (۵)$$

با جایگذاری مقادیر عددی، ساختار دقیق ضرب عبارت است از:

$${}^0P_{homogeneous} = {}^0T_E \cdot \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 5 \\ 0 & 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 10 \\ -1 \\ 2 \\ 1 \end{bmatrix} \quad (۶)$$



سوال ۲

(۱) تأثیر اشتباه بر ماتریس‌های انتقال A_i

در قرارداد DH، ترم‌های متغیر مفصلی (θ_i) و انتقال محوری (d_i) بر اساس محور Z تعریف می‌شوند. قرار دادن محور Z در راستای طول لینک به جای محور مفصل، پیامدهای زیر را دارد:

- جابجایی هندسی پارامترها: پارامتر a_i (طول لینک) که باید به عنوان انتقال در راستای X_i اعمال شود، به عنوان انتقال در راستای Z ظاهر شده و جای ترم‌های مربوط به a_i و d_i درون ماتریس همگن A_i عوض می‌شود.
- توصیف نادرست دوران: ماتریس ریاضی بر پایه چرخش حول Z است. با تغییر جهت این محور، فرمول‌ها دیگر قادر به توصیف درست حرکت دورانی واقعی مفصل ربات نیستند.

(۲) دلیل تأکید DH بر انطباق محور Z با محور مفصل (Joint Axis)

- تطابق با متغیرهای مفصلی: برای اینکه رفتار ریاضی مدل با متغیرهای فیزیکی موتورها (زوایای θ_i برای مفاصل دورانی) کاملاً همگام باشد، قرارداد DH محرک مستقل هر درجه آزادی را منحصرأ روی محور Z آن مفصل تعریف می‌کند.
- جداسازی روابط حرکتی: (Decoupling) این کار مانع از جفت‌شدن (Coupling) پیچیده درجات آزادی می‌شود. در صورت عدم رعایت، تغییر یک زاویه مفصل به جای یک دوران ساده، به صورت ترکیبی ناخواسته از دوران و انتقال‌های کاذب در ماتریس دیده خواهد شد.



۲ سوال ۳

شکل ۲

سوال ۴

(۱) تعریف ریاضی فیلتر Sobel در راستای افقی (G_x)

فیلتر لبه‌یاب Sobel در راستای افقی (که وظیفه سنجش گرادیان و تغییرات شدت روشنایی در امتداد محور افقی با همان ستون‌ها را دارد)، به صورت یک ماتریس 3×3 استاندارد زیر تعریف می‌شود:

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad (۷)$$

(۲) محاسبات دستی کانولوشن برای پیکسل مرکزی

ماتریس تصویر ورودی I با ابعاد 3×3 به صورت زیر داده شده است:

$$I = \begin{bmatrix} 10 & 10 & 100 \\ 10 & \mathbf{10} & 100 \\ 10 & 10 & 100 \end{bmatrix} \quad (۸)$$

هدف، محاسبه مقدار خروجی فیلتر برای پیکسل مرکزی (در موقعیت سطر دوم و ستون دوم با مقدار 10) بدون در نظر گرفتن Padding است. عملگر کانولوشن (ضرب نقطه‌ای درایوهای متناظر ماسک فیلتر بر روی همسایگی تصویر و مجموع آن‌ها) به صورت زیر محاسبه می‌شود:

$$\text{Output} = \sum_{i=1}^3 \sum_{j=1}^3 (I_{ij} \times G_{x,ij})$$

با جایگذاری مقادیر ماتریس تصویر I و فیلتر G_x ، محاسبات سطر به سطر به شرح زیر است:

$$\begin{aligned} \text{سطر اول} & \leftarrow \text{Output} = (10 \times (-1) + 10 \times 0 + 100 \times 1) \\ & + (10 \times (-2) + 10 \times 0 + 100 \times 2) \quad \leftarrow \text{سطر دوم} \\ & + (10 \times (-1) + 10 \times 0 + 100 \times 1) \quad \leftarrow \text{سطر سوم} \end{aligned}$$

حاصل عددی هر سطر عبارت است از:

• سطر اول: $-10 + 0 + 100 = 90$

• سطر دوم: $-20 + 0 + 200 = 180$

• سطر سوم: $-10 + 0 + 100 = 90$

مجموع نهایی برای پاسخ پیکسل مرکزی:

$$\text{Output} = 90 + 180 + 90 = 360 \quad (۹)$$

بنابراین، مقدار خروجی فیلتر برای پیکسل مرکزی برابر 360 است.

۳) تفسیر مفهومی نتیجه در خصوص جهت و شدت گرادیان لبه

خروجی حاصل شده (360) حاوی اطلاعات فیزیکی و هندسی زیر از ساختار تصویر در این همسایگی است:

۱. شدت گرادیان لبه (Edge): (Magnitude) مقدار عددی بزرگ به دست آمده (360) بیانگر وجود یک لبه‌ی بسیار تیز و با تباین (کنتراست) بالا در این ناحیه است که ناشی از جهش ناگهانی شدت روشنایی از غلظت 10 به 100 در ستون سوم تصویر می‌باشد.

۲. جهت لبه و گرادیان (Edge & Gradient): (Direction)

- امتداد هندسی لبه: با توجه به اینکه مقادیر ستون‌های اول و دوم همگی 10 و ستون سوم همگی 100 هستند، تغییرات موازی سطرها رخ داده و خود خط لبه به صورت یک لبه‌ی کاملاً عمودی (Vertical) (Edge) ظاهر شده است.
- جهت بردار گرادیان: علامت مثبت خروجی (+360) نشان می‌دهد که بردار گرادیان (جهت بیشترین افزایش شدت روشنایی) دقیقاً در امتداد محور افقی مثبت و از چپ به راست (زاویه 0°) است؛ یعنی تصویر با حرکت به سمت راست، به شدت روشن‌تر می‌شود.



سوال ۵

مقدمه و تعریف تابع فعال ساز سیگموید

تابع فعال ساز سیگموید (Sigmoid) به صورت زیر تعریف می شود:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (10)$$

مشتق این تابع نسبت به ورودی آن، رابطه بسیار معروفی دارد که برحسب خود تابع خروجی بیان می شود:

$$\sigma'(x) = \sigma(x)(1 - \sigma(x)) \quad (11)$$

$$\frac{df}{ds} = 1 - 2s = 0 \implies s = 0.5$$

با جایگذاری $s = 0.5$ در رابطه مشتق، حداکثر مقدار آن به دست می آید:

$$\max(\sigma'(x)) = 0.5 \times (1 - 0.5) = 0.25 \quad (12)$$

بنابراین، برای هر ورودی دلخواه x ، همواره رابطه زیر برقرار است:

$$0 < \sigma'(x) \leq 0.25 \quad (13)$$

اثبات مفهومی پدیده گرادیان محو شونده (Vanishing Gradient) با قاعده زنجیره ای

$$\frac{\partial J}{\partial w^{(1)}} = \frac{\partial J}{\partial a^{(L)}} \cdot \frac{\partial a^{(L)}}{\partial z^{(L)}} \cdot \frac{\partial z^{(L)}}{\partial a^{(L-1)}} \cdots \frac{\partial a^{(2)}}{\partial z^{(2)}} \cdot \frac{\partial z^{(2)}}{\partial a^{(1)}} \cdot \frac{\partial a^{(1)}}{\partial z^{(1)}} \cdot \frac{\partial z^{(1)}}{\partial w^{(1)}} \quad (14)$$

از آنجا که $\frac{\partial a^{(l)}}{\partial z^{(l)}} = \sigma'(z^{(l)})$ و $\frac{\partial z^{(l)}}{\partial a^{(l-1)}} = w^{(l)}$ است، رابطه فوق را می توان به شکل زیر خلاصه کرد:

$$\frac{\partial J}{\partial w^{(1)}} = \frac{\partial J}{\partial a^{(L)}} \cdot \left(\prod_{i=2}^L w^{(i)} \cdot \sigma'(z^{(i)}) \right) \cdot \sigma'(z^{(1)}) \cdot a^{(0)} \quad (15)$$

تحلیل صفر شدن سیگنال خطا در لایه های اول:

۱. اثر حاصل ضرب متوالی اعداد کوچک: از آنجا که مقدار $\sigma'(z)$ همواره کوچکتر یا مساوی ۰.۲۵ است، در یک شبکه عمیق با افزایش تعداد لایه ها، عبارت $\prod \sigma'(z^{(i)})$ حاصل ضربی از تعداد زیادی عدد کوچک (کمتر از ۰.۲۵) خواهد بود. به عنوان مثال، تنها برای ۵ لایه متوالی، این اثر مرتبه ای در حدود $0.00097 \approx (0.25)^5$ ایجاد می کند.

۲. مکانیزم اشباع (Saturation): اگر ورودی لایه ها (z) مقادیر خیلی بزرگ یا خیلی کوچک به خود بگیرند، مقدار مشتق سیگموید به شدت به سمت صفر میل می کند ($\sigma'(x) \rightarrow 0$).

در نتیجه این دو عامل، با حرکت سیگنال خطا از لایه های انتهایی به سمت لایه های ابتدایی، مقدار گرادیان به صورت نمایی کاهش یافته و در لایه های اول عملاً **صفر** می شود. وقتی گرادیان صفر شود، وزن های لایه های ابتدایی به روزرسانی نشده و فرآیند آموزش شبکه های عمیق متوقف می گردد.

راهکارهای مدرن در معماری شبکه‌های CNN برای رفع این مشکل

معماری‌های مدرن بینایی ماشین (CNN) از چندین تکنیک کلیدی برای حفظ فرآیند جریان گرادیان در لایه‌های عمیق استفاده می‌کنند:

۱. استفاده از تابع فعال‌ساز ReLU و مشتقات آن: به جای توابع محدودکننده مثل Sigmoid از تابع $f(x) = \max(0, x)$ استفاده می‌شود. مشتق این تابع برای ورودی‌های مثبت همواره دقیقاً برابر 1 است ($\sigma'(x) = 1$). این ویژگی باعث می‌شود که سیگنال گرادیان بدون تضعیف و کاهش نمایی از لایه‌ها عبور کند.

۲. اتصالات باقیمانده (Residual Connections): Skip / Connections در معماری‌هایی مانند ResNet، از اتصالات میان‌بر استفاده می‌شود که ورودی یک لایه را مستقیماً به چند لایه جلوتر جمع می‌کند ($y = F(x) + x$). در هنگام پس‌انتشار، مشتق این رابطه ترم $+1$ را به جریان گرادیان اضافه می‌کند:

$$\frac{\partial y}{\partial x} = \frac{\partial F(x)}{\partial x} + 1$$

این مقدار 1 تضمین می‌کند که حتی اگر گرادیان مسیر اصلی ($F(x)$) صفر شود، سیگنال خطا از طریق مسیر میان‌بر بدون هیچ مانعی مستقیماً به لایه‌های ابتدایی منتقل شود.

۳. لایه نرمال‌سازی دسته‌ای (Batch Normalization): این لایه ورودی هر لایه را به گونه‌ای نرمال‌سازی می‌کند که میانگین صفر و واریانس یک داشته باشند. این کار مانع از بزرگ شدن بیش از حد یا کوچک شدن ورودی‌ها شده و از ورود توابع فعال‌ساز به نواحی اشباع (جایی که مشتق صفر است) جلوگیری می‌کند.

سوال ۶

الف) محاسبه ابعاد فضایی (ارتفاع و عرض) تانسور خروجی

برای محاسبه ابعاد فضایی خروجی یک لایه کانولوشن دوبعدی (H_{out} و W_{out})، از فرمول استاندارد زیر استفاده می‌کنیم:

$$N_{out} = \left\lfloor \frac{N_{in} - K + 2P}{S} \right\rfloor + 1 \quad (۱۶)$$

که در آن پارامترهای داده شده در مسئله عبارتند از:

• ابعاد فضایی ورودی (N_{in}): 128 (با توجه به تانسور ورودی $3 \times 128 \times 128$)

• ابعاد فیلتر K یا Kernel Size: 5

• حاشیه P یا: 2 Padding

• گام حرکت S یا: 2 Stride

با جایگذاری این مقادیر در فرمول، محاسبات به صورت زیر انجام می‌شود:

$$\begin{aligned} H_{out} = W_{out} &= \left\lfloor \frac{128 - 5 + 2(2)}{2} \right\rfloor + 1 \\ &= \left\lfloor \frac{128 - 5 + 4}{2} \right\rfloor + 1 \\ &= \left\lfloor \frac{127}{2} \right\rfloor + 1 \\ &= \lfloor 63.5 \rfloor + 1 \\ &= 63 + 1 = 64 \end{aligned}$$

نتیجه بخش الف: ابعاد فضایی تانسور خروجی برابر با 64×64 است (ابعاد کامل تانسور خروجی با احتساب تعداد کانال‌ها $64 \times 64 \times 64$ خواهد بود).

ب) تعداد کل پارامترهای قابل آموزش (Trainable Parameters) با احتساب Bias

فرمول کلی برای محاسبه تعداد پارامترهای قابل آموزش در یک لایه کانولوشن استاندارد عبارت است از:

$$\text{Parameters Total} = (K_H \times K_W \times C_{in} \times C_{out}) + C_{out} \quad (۱۷)$$

که در آن پارامترها به شرح زیر تعریف می‌شوند:

• $K_H \times K_W$ (ابعاد فیلتر): 5×5

• C_{in} (تعداد کانال‌های ورودی): 3

• C_{out} (تعداد کانال‌های خروجی / تعداد فیلترها): 64

• C_{out} (تعداد لایه‌های بایاس): 64 (به تعداد کانال‌های خروجی، بایاس آموزش‌پذیر داریم)

مراحل محاسبه عددی:

۱. تعداد وزن‌ها: (Weights)

$$5 \times 5 \times 3 \times 64 = 25 \times 3 \times 64 = 75 \times 64 = 4800$$

۲. تعداد بایاس‌ها: (Biases) 64

۳. مجموع کل پارامترها:

$$\text{Parameters Total} = 4800 + 64 = 4864$$

نتیجه بخش ب: تعداد کل پارامترهای قابل آموزش در این لایه برابر با 4864 است.



۳ سوال ۷

$P=1$ $K=3$ $out_c=16$ $in_c=3$ $\xrightarrow{\text{self.conv1}}$ $\text{فریبی تا ۷} \Rightarrow \text{فریبی تا ۷}$ $\text{stride default}=1$

$w_{out} = \left\lfloor \frac{in_c - K + 2P}{S} \right\rfloor + 1 \Rightarrow \left\lfloor \frac{64 - 3 + 2}{1} \right\rfloor + 1 = 64$

relu $\text{اجرای تدریس از کانولوشن، تابع فعال‌ساز}$

$[B, 16, 64, 64]$

$[B, 16, 32, 32]$ $\xrightarrow{\text{self.pool}}$ $w_{pool} = \frac{w_{64}}{2} = 32$ فریبی

$\text{channel} \times \text{width} \times \text{height} = 16 \times 32 \times 32 = 16384$ $\text{مجموعه ابعاد after شده}$

$16 \times 32 \times 32$ view $\text{برای view برابر است با}$

flatten کردن adaptive $\text{برای ابعاد مناسب‌تر به ابعاد بهتر تا از اطلاعات}$ avg pool

init باید توای $\text{self.adaptive_pool} = \text{nn.adaptive_avg_pool2d}(16, 16)$

$\text{forward (self, x):}$ $x = \text{self.pool}(\text{F.relu}(\text{self.conv1}(x)))$ تبدیل

$x = \text{self.adaptive_pool}(x)$

$x = x.view(-1, 16 * 16 * 16)$

$x = \text{self.fc1}(x)$

کد املاح نه

شکل ۳



۴ سوال ۸

برای ج ۷ عملیات opening ترکیب از ۷ ابتدا Erosion و پھر Dilation
 چرا cv2.morph_open با kernel 5x5 اسبابہ ہے ؟
 پہلے پہلے سوال سے مراد داری ترکھائی یا رنارک سیدھے درہے زبے تھیں
 چون ترکھائی فلی نائزہ دایم و مختصہ تھیں کو چکھتہ واز مہرنی Erosion با د ہری کلوزائی کے ری
 بہم ہائی سید مرکبہ حتی یکھد پھل ہائی زیر کرنل سیاہ با تھ پھل مرکزی سیاہ ہے ،
 درستہ ہے سارے ہر ترکھائی ہر با مکمل ناز ہے و تھائی ہائی ناز و سیاہ چکھتہ
 وقتی این اتھاقی بیوٹہ فردی یکھد سیر مائل سیاہ ہے و Dilation دلیہ مزی ہیدا تھکے
 در واقع ہے حال منوان نیز در نظر تھتہ تھیں
 راہ حل ہے ؟ استاد از cv2.morph_close سے پہلے اول Dilation درہے Erosion
 Dilation با تھ ہے خطوط نازک کا منہ تر ہے یا اتر تھئی در رکھائی و دوبارہ کے ریز سس تھائی ہم مصلحتی
 سولہ در Erosion با تھ ہے کمی از این مختصہ اضافہ تھہ حذف ہے و ان ترکھائی نازک حذف تھوند

شکل ۴