



دانشگاه صنعتی خواجه نصیرالدین طوسی
دانشکده مهندسی برق

درس رباتیک و بینایی ماشین

استاد: دکتر حمیدرضا تقی راد

استاد: دکتر محمدجواد احمدی

تحقیق شماره یک

گروه آزادی

نام و نام خانوادگی	محمدامین محمدیون شبستری
شماره دانشجویی	۴۰۱۲۲۵۰۳
نام و نام خانوادگی	محمدسبحان سخایی
شماره دانشجویی	۴۰۱۱۹۲۵۳
نام و نام خانوادگی	هستی محمدی
شماره دانشجویی	۴۰۲۲۱۲۴۳
تاریخ	اردیبهشت ۱۴۰۵



فهرست مطالب

۱	موضوع سوم: یادگیری عمیق هندسی (Geometric Deep learning)؛ وقتی هوش مصنوعی هندسه فضایی را می فهمد!	۲
۱.۱	گروه‌های لی ($SE(3)$ و $SO(3)$) (گردآورنده: محمد سبحان سخایی)	۲
۱.۱.۱	گروه‌های لی و درک حرکت در رباتیک	۲
۲.۱.۱	چرا امروزه به جای «ماتریس تبدیل همگن» از $SE(3)$ استفاده می‌شود؟	۳
۳.۱.۱	مثال ساده از یادگیری عمیق هندسی	۳
۲.۱	هم‌وردایی در شبکه‌های عصبی (گردآورنده: محمدامین شبستری)	۳
۱.۲.۱	مقدمه: تقارن، هندسه و یادگیری عمیق	۳
۲.۲.۱	ناوردایی و هم‌وردایی در توابع و شبکه‌های عصبی	۴
۳.۲.۱	گروه $SE(3)$ و مفهوم $SE(3)$ -Equivariance	۴
۴.۲.۱	طراحی شبکه‌های $SE(3)$ -Equivariant	۵
۵.۲.۱	کاهش نیاز به داده‌های تکراری با $SE(3)$ -Equivariance	۵
۶.۲.۱	جمع‌بندی	۶
۳.۱	انقلاب در کنترل ربات‌ها ($SE(3)$ Transformers) (گردآورنده: هستی محمدی)	۶
۱.۳.۱	تأثیر بر حوزه‌های Grasping و Imitation Learning و نحوه انتخاب بهترین ماتریس چرخش برای گرفتن شی	۷



۱ موضوع سوم: یادگیری عمیق هندسی (Geometric Deep learning)؛ وقتی هوش مصنوعی هندسه فضایی را می فهمد!

۱.۱ گروه‌های لی ($SE(3)$ و $SO(3)$) (گردآورنده: محمد سبحان سخایی)

در سال‌های اخیر، شبکه‌های عصبی در تشخیص تصویر پیشرفت فوق‌العاده‌ای داشته‌اند. برای مثال، اگر هزاران تصویر از یک گربه به شبکه نشان دهیم، شبکه کم‌کم یاد می‌گیرد که گربه را تشخیص دهد. اما در رباتیک و بینایی ماشین، مسئله فقط تشخیص یک تصویر ساده نیست؛ ربات باید اشیاء را در دنیای واقعی و سه‌بعدی درک کند.

فرض کنید یک بازوی رباتیک می‌خواهد یک لیوان را بردارد. این لیوان ممکن است روی میز چرخیده باشد، کج قرار گرفته باشد یا حتی در جای دیگری از تصویر دیده شود. در روش‌های قدیمی، برای اینکه شبکه عصبی بتواند لیوان را در همه حالت‌ها بشناسد، باید هزاران تصویر از همان لیوان در زاویه‌ها و موقعیت‌های مختلف به آن نشان داده می‌شد. به این کار «افزونه‌سازی داده» (Data Augmentation) گفته می‌شود. اما این روش هم زمان‌بر است و هم باعث می‌شود شبکه فقط با تکرار زیاد، الگوها را حفظ کند، نه اینکه واقعاً مفهوم فضا و چرخش را بفهمد.

اینجاست که «یادگیری عمیق هندسی» (Geometric Deep Learning) وارد می‌شود [۱]. ایده اصلی این شاخه آن است که به جای حفظ کردن هزاران تصویر مختلف، خود قوانین هندسی و چرخش‌های فضا را داخل ساختار شبکه عصبی قرار دهیم. یعنی شبکه از ابتدا بداند که اگر یک جسم بچرخد یا جابه‌جا شود، هنوز همان جسم است.

۱.۱.۱ گروه‌های لی و درک حرکت در رباتیک

برای توصیف حرکت در فضا، در رباتیک از مفهومی به نام «گروه‌های لی» (Lie Groups) استفاده می‌شود [۲]. این گروه‌ها زبان ریاضی حرکت و چرخش در فضای سه‌بعدی هستند.

توصیف چرخش در فضای $SO(3)$ گروه $SO(3)$ تمام چرخش‌های ممکن در فضای سه‌بعدی را توصیف می‌کند (چرخش دور x ، چرخش دور y و چرخش دور z).

برای درک بهتر، یک گوشی موبایل را در دست بگیرید. اگر فقط آن را بچرخانید، بدون اینکه جابه‌جا شود، حرکت شما در فضای $SO(3)$ قرار می‌گیرد؛ مثلاً چرخاندن گوشی به چپ و راست، بالا و پایین کردن آن یا چرخش دور خودش. همه این حرکات نمونه‌ای از چرخش سه‌بعدی هستند.

در رباتیک نیز وقتی دوربین یک پهپاد تغییر زاویه می‌دهد یا مفصل یک بازوی رباتیک می‌چرخد، در واقع در فضای $SO(3)$ حرکت می‌کند. این مفهوم کمک می‌کند ربات بتواند جهت اجسام را به درستی درک کند.

چرخش و جابه‌جایی همزمان $SE(3)$ در دنیای واقعی، اجسام فقط نمی‌چرخند؛ بلکه جابه‌جا هم می‌شوند. گروه $SE(3)$ ترکیبی از چرخش (Rotation) و جابه‌جایی (Translation) است.

مثلاً فرض کنید یک پهپاد هم به جلو حرکت می‌کند و هم دور خودش می‌چرخد. یا یک بازوی رباتیک دستش را به سمت لیوان می‌برد و همزمان می‌چرخد تا لیوان را درست بگیرد. این نوع حرکت کامل، در فضای $SE(3)$ توصیف می‌شود. در واقع، هر «وضعیت» یا Pose یک ربات در فضا شامل مکان و جهت آن است که هر دو با هم توسط $SE(3)$ بیان می‌شوند.



۲.۱.۱ چرا امروزه به جای «ماتریس تبدیل همگن» از $SE(3)$ استفاده می‌شود؟

در کتاب‌های قدیمی رباتیک معمولاً از «ماتریس تبدیل همگن» استفاده می‌شد. این ماتریس‌ها ابزاری بودند برای اینکه چرخش و جابه‌جایی را در قالب یک ماتریس 4×4 بنویسیم. اما در مقالات مدرن هوش مصنوعی و رباتیک، بیشتر از نماد $SE(3)$ استفاده می‌شود. دلیل آن این است که $SE(3)$ فقط یک ماتریس نیست، بلکه مفهوم واقعی حرکت در فضای سه‌بعدی را توصیف می‌کند. برای درک بهتر، فرض کنید بخواهیم به یک شبکه عصبی یاد بدهیم موقعیت یک دوربین را پیش‌بینی کند. اگر فقط بگوییم:

«این ۱۶ عدد ماتریس را یاد بگیر»

شبکه ممکن است خروجی اشتباهی تولید کند؛ مثلاً ماتریسی که از نظر ریاضی معتبر باشد اما از نظر فیزیکی غیرممکن باشد. اما وقتی از مفهوم $SE(3)$ استفاده می‌کنیم، شبکه می‌فهمد که جسم باید صلب باقی بماند، طول‌ها نباید تغییر کنند و حرکت باید واقعی و فیزیکی باشد. به همین دلیل، در یادگیری عمیق هندسی، شبکه‌ها طوری طراحی می‌شوند که قوانین چرخش و حرکت را ذاتاً رعایت کنند [۳].

۳.۱.۱ مثال ساده از یادگیری عمیق هندسی

فرض کنید یک ربات می‌خواهد یک لیوان را تشخیص دهد. در روش قدیمی، باید هزاران تصویر از لیوان در زاویه‌های مختلف به شبکه نشان دهیم. اما در یادگیری عمیق هندسی، شبکه مفهوم چرخش را می‌فهمد؛ بنابراین اگر لیوان بچرخد، باز هم آن را همان لیوان تشخیص می‌دهد. یعنی شبکه فقط تصویر را حفظ نمی‌کند؛ بلکه ساختار هندسی جسم را درک می‌کند. به همین دلیل، یادگیری عمیق هندسی امروزه در خودروهای خودران، ربات‌های جراح، پهپادها و بینایی ماشین سه‌بعدی کاربرد بسیار مهمی پیدا کرده است [۴].

۲.۱ هم‌وردایی در شبکه‌های عصبی (گردآورنده: محمدمامین شبستری)

۱.۲.۱ مقدمه: تقارن، هندسه و یادگیری عمیق

بسیاری از داده‌هایی که در هوش مصنوعی با آن‌ها سروکار داریم، ساختار هندسی دارند: تصاویر دو بعدی، ابرنقاط و مدل‌های سه‌بعدی، مولکول‌ها، وضعیت بازوی ربات و داده‌های فیزیکی مانند میدان‌های نیرو. این داده‌ها تحت تبدیلات هندسی‌ای مانند چرخش و انتقال معنای خود را از دست نمی‌دهند؛ به این معنا که اگر یک شیء سه‌بعدی را در فضا بچرخانیم یا جابه‌جا کنیم، خود شیء تغییر نمی‌کند، بلکه فقط نمایش آن دگرگون می‌شود. این نوع رفتار در ریاضیات با مفهوم symmetry و گروه‌های تبدیلات توصیف می‌شود [۱]. در یادگیری عمیق، اگر شبکه‌ای عصبی این تقارن‌ها را «بشناسد» و معماری آن مطابق این ساختارها طراحی شده باشد، می‌تواند کارآمدتر یاد بگیرد؛ یعنی با داده‌ی کمتر، تعمیم بهتر و سازگاری بیشتر با قوانین فیزیکی. شاخه‌ای که به طور سیستماتیک این ایده‌ها را بررسی می‌کند، امروزه با عنوان Geometric Deep Learning شناخته می‌شود [۱].

۲.۲.۱ ناوردایی و هموردایی در توابع و شبکه‌های عصبی

ناوردایی (Invariance). فرض کنید تابعی f روی داده‌ی x تعریف شده و گروهی از تبدیلات G روی فضای ورودی عمل می‌کند. می‌گوییم f نسبت به عمل گروه G invariant است، اگر برای همه‌ی $g \in G$ داشته باشیم:

$$f(g \cdot x) = f(x). \quad (۱)$$

به صورت شهودی، این یعنی اگر ورودی را مطابق هر تبدیل مجاز در گروه تغییر دهیم، خروجی ثابت می‌ماند. برای مثال، در مسئله‌ی تشخیص «آیا در تصویر گربه هست یا نه»، اگر تصویر را کمی در صفحه جابه‌جا کنیم، برچسب «گربه» باید ثابت بماند. در شبکه‌های Convolutional Neural Networks (CNNs)، با استفاده از عملیات pooling روی نقشه‌های ویژگی، نوعی ناوردایی تقریبی نسبت به انتقال به دست می‌آید [۵، ۶].

هموردایی (Equivariance). تابع f نسبت به G equivariant است اگر:

$$f(g \cdot x) = \rho(g) f(x), \quad (۲)$$

که در آن ρ یک نمایش (representation) از گروه روی فضای خروجی است [۳، ۷]. شهودی یعنی اگر ورودی را با g تغییر دهیم، خروجی نیز به روشی سازگار با همان g تغییر می‌کند. به عنوان مثال، اگر شبکه‌ای مختصات یک شیء در تصویر را برمی‌گرداند و تصویر را ۱۰ پیکسل به راست منتقل کنیم، مختصات خروجی نیز باید ۱۰ پیکسل جابه‌جا شوند. در این جا عمل گروه روی ورودی و خروجی هر دو «انتقال» است و شبکه نسبت به آن هموردا است.

شبکه‌های CNN کلاسیک دقیقاً به واسطه‌ی ساختار کانولوشن، نسبت به گروه انتقال روی گرید دوبعدی هموردا هستند؛ اگر تصویر را جابه‌جا کنید، نقشه‌های ویژگی نیز به همان میزان جابه‌جا می‌شوند [۳]. این نخستین نمونه‌ی موفق بهره‌گیری از خاصیت equivariance در یادگیری عمیق است.

۳.۲.۱ گروه $SE(3)$ و مفهوم $SE(3)$ -Equivariance

تعریف گروه $SE(3)$. گروه $SE(3)$ (Special Euclidean group in 3D) مجموعه‌ی تمام تبدیلات سفت و سخت (rigid) در فضای سه بعدی است؛ یعنی ترکیب یک چرخش و یک انتقال:

$$x' = Rx + t, \quad (۳)$$

که در آن $R \in SO(3)$ یک ماتریس چرخش 3×3 و $t \in \mathbb{R}^3$ یک بردار انتقال است [۱]. اعمال پی‌درپی در چنین تبدیلهایی باز هم به یک تبدیل از همین نوع منجر می‌شود؛ بنابراین مجموعه‌ی این تبدیلات یک گروه تشکیل می‌دهد. این گروه مدل استاندارد حرکت اجسام صلب در رباتیک، بینایی سه بعدی و شیمی محاسباتی است. هر بار که می‌گوییم «این شیء را در فضا بچرخان و جابه‌جا کن»، در عمل در حال اعمال عنصری از $SE(3)$ هستیم.

تعریف $SE(3)$ -Equivariance برای شبکه‌های عصبی. فرض کنید داده‌ی ورودی مجموعه‌ای از نقاط سه بعدی $\{x_i\}_{i=1}^n \subset \mathbb{R}^3$ همراه با ویژگی‌هایی روی هر نقطه باشد (مانند اتم‌های یک مولکول، نقاط روی سطح یک جسم یا voxels در تصویر پزشکی). یک شبکه‌ی عصبی f را $SE(3)$ -equivariant می‌نامیم اگر برای هر تبدیل $g = (R, t) \in SE(3)$ داشته باشیم:

$$f(g \cdot x) = g \cdot f(x). \quad (۴)$$



به عبارت دیگر، اگر ورودی را با چرخش و انتقال g تغییر دهیم، خروجی نیز به طور منظم با همان چرخش و انتقال تغییر می کند. در بسیاری از شبکه های SE(3)-equivariant، عمل گروه روی خروجی می تواند پیچیده تر باشد و شامل چرخش تنسورهای برداری و تنسورهای با رتبه ی بالاتر شود [۴، ۸، ۹].

این خاصیت باعث می شود شبکه به صورت درونی بداند که جهت گیری و مکان مطلق در فضا اهمیت اصلی را ندارد؛ بلکه ساختار نسبی و روابط هندسی میان نقاط مهم است. در نتیجه، برخلاف شبکه های معمولی، لازم نیست همان شیء را در تعداد زیادی زاویه و مکان مختلف به شبکه نشان دهیم تا آن را یاد بگیرد.

۴.۲.۱ طراحی شبکه های SE(3)-Equivariant

در شبکه های SE(3)-equivariant هر لایه باید خاصیت هموردایی را حفظ کند؛ یعنی اگر ورودی تحت عمل $SE(3)$ طبق یک نمایش گروهی تغییر کند، خروجی نیز تحت نمایش سازگار دیگری تغییر کند. این ایده معمولاً با سه اصل اجرا می شود:

نمایش پذیری ویژگی ها (Feature Representations). ویژگی های هر نقطه به اسکالر، بردار و تنسورهای با رتبه ی بالاتر تجزیه می شوند که هر کدام تحت چرخش و انتقال، رفتار مشخصی دارند. این رفتار با نمایش های مختلف $SO(3)$ مدل می شود [۴، ۸].

عملگرهای هموردا (Equivariant Operators). لایه ها به گونه ای طراحی می شوند که تغییر هماهنگ ورودی ها با گروه، به تغییری سازگار در خروجی منجر شود. این کار با ساخت کرنل های کانولوشن مبتنی بر spherical harmonics و تجزیه ی Clebsch–Gordan انجام می شود تا خود کرنل ها ساختار equivariant داشته باشند [۴، ۱].

۵.۲.۱ کاهش نیاز به داده های تکراری با SE(3)-Equivariance

در شبکه های معمولی، برای آن که مدل یک شیء را در زاویه ها و موقعیت های مختلف بشناسد، باید نمونه های زیادی از همان شیء در حالات گوناگون به آن نشان داد؛ زیرا مدل به طور ساختاری نمی داند که چرخش و جابه جایی، همان شیء را حفظ می کند و این موضوع فقط از داده آموخته می شود. این امر به نیاز شدید به data augmentation منجر می شود [۵]. در مقابل، در شبکه های SE(3)-equivariant رابطه ی

$$f(g \cdot x) = g \cdot f(x), \quad \forall g \in SE(3), \quad (5)$$

در سطح معماری تضمین شده است [۳، ۴، ۸، ۹، ۱]. بنابراین، مشاهده ی یک پیکربندی واحد از یک شیء کافی است تا رفتار مدل نسبت به همه ی تبدیلات $SE(3)$ مشخص شود. به این ترتیب:

- نیاز به data augmentation گسترده کاهش می یابد،
- تعمیم به حالت های نادیده گرفته شده بهبود می یابد،
- مدل نسبت به تغییرات هندسی پایدارتر می شود [۴، ۸، ۱].



۶.۲.۱ جمع بندی

مفهوم Equivariance پلی است میان هندسه‌ی ریاضی و طراحی شبکه‌های عصبی. با در نظر گرفتن داده‌ها به عنوان اشیای هندسی که تحت گروه‌هایی مانند $SE(3)$ تغییر می‌کنند، می‌توان معماری‌هایی ساخت که تغییرات هندسی را به طور ذاتی درک کنند. گروه $SE(3)$ که چرخش و انتقال را در فضای سه بعدی مدل می‌کند، در مسائل رباتیک، شیمی، بینایی سه بعدی و پزشکی اهمیت بنیادی دارد. شبکه‌های $SE(3)$ -equivariant با استفاده از نمایش‌های گروهی، تنسورهای میدان و عملگرهای equivariant، این تقارن‌ها را در هر لایه حفظ می‌کنند. نتیجه آن است که شبکه برای یادگیری رفتار صحیح در برابر چرخش و انتقال، نیازی به مشاهده‌ی تعداد زیادی نمونه‌ی تکراری از داده در زاویه‌ها، موقعیت‌های مختلف ندارد؛ بلکه این رفتار از ابتدا در معماری کدگذاری شده است. این امر موجب کاهش نیاز به داده، افزایش تعمیم و عملکرد بهتر در مسائل فیزیکی و سه بعدی شده است [۳، ۴، ۸، ۹، ۱].

۳.۱ انقلاب در کنترل ربات‌ها ($SE(3)$ Transformers) (گردآورنده: هستی محمدی)

ترانسفورمرهای $SE(3)$ یکی از مهم‌ترین پیشرفت‌ها در یادگیری عمیق هندسی به شمار می‌رود. این مدل با اضافه کردن خاصیت هم‌وردایی نسبت به چرخش و جابه‌جایی، به ربات‌ها امکان می‌دهد محیط را شبیه‌تر به یک انسان تحلیل و درک کنند؛ به طوری که ربات می‌تواند تصویر سه بعدی محیط را از دور بین دریافت، ساختار جسم را درک و بهترین ماتریس چرخش را محاسبه کند و در نهایت با دقت بالا جسم را بگیرد یا حرکتی پیچیده را تقلید کند.

تعریف ترانسفورمر ترانسفورمر (Transformer) یکی از مهم‌ترین معماری‌های Deep Learning در سال‌های اخیر است که ابتدا برای پردازش زبان طبیعی (NLP) معرفی شد، اما به مرور زمان کاربرد آن به حوزه‌های دیگری مانند بینایی ماشین، پردازش تصاویر سه بعدی و رباتیک نیز گسترش پیدا کرد. ایده‌ی اصلی ترانسفورمر بر پایه Attention است که به مدل اجازه می‌دهد تشخیص دهد کدام بخش از داده‌های ورودی اهمیت بیشتری دارند و باید بیشتر مورد توجه قرار گیرند.

مزیت اصلی ترانسفورمرها این است که می‌توانند روابط پیچیده بین اجزای داده را به خوبی یاد بگیرند و هم‌زمان حجم زیادی از اطلاعات را پردازش کنند. همین ویژگی باعث شده است که این معماری در بسیاری از مسائل پیشرفته‌ی هوش مصنوعی و درک محیط توسط ربات‌ها، بسیار کاربردی باشند [۱۰].

ترانسفورمرهای خاص $SE(3)$ با وجود موفقیت زیاد ترانسفورمرهای معمولی، این مدل‌ها برای داده‌های سه بعدی محدودیت‌هایی دارند؛ بر فرض مثال اگر یک جسم در فضا بچرخد یا جابه‌جا شود، ممکن است مدل آن را به عنوان یک ورودی کاملاً متفاوت در نظر بگیرد که در مسائل رباتیک مشکل ساز است؛ چرا که ربات باید بتواند یک جسم را در هر زاویه و هر موقعیتی تشخیص دهد. برای حل این مشکل، مدل $SE(3)$ -Transformer معرفی شد. این مدل نسخه‌ای از ترانسفورمر است که به طور خاص برای داده‌های سه بعدی طراحی شده و نسبت به چرخش و جابه‌جایی اجسام مقاوم است.

$$SE(3) = SO(3) + Translation$$

در این رابطه، $SO(3)$ مربوط به چرخش‌های سه بعدی و بخش Translation مربوط به انتقال یا جابه‌جایی در فضا است. ایده‌ی کلیدی در این مدل ترانسفورمر، مفهوم Equivariance یا هم‌وردایی است. منظور از هم‌وردایی این است که اگر ورودی شبکه بچرخد یا جابه‌جا شود، خروجی مدل نیز باید به همان شکل تغییر کند، نه اینکه کاملاً نادرست شود و مدل باید نسبت به تغییر دستگاه مختصات حساس نباشد.



یکی از تفاوت‌های مهم SE(3)-Transformer با ترنسفورمرهای معمولی این است که این مدل مستقیماً روی Point Cloud کار می‌کند. Point Cloud مجموعه‌ای از نقاط سه‌بعدی است که معمولاً توسط دوربین‌های عمق‌سنج (RGB-D) تولید می‌شود. مدل با تحلیل روابط میان نقاط این مجموعه، ساختار هندسی جسم یا محیط را یاد می‌گیرد. به همین دلیل، این معماری برای کاربردهای رباتیکی که نیاز به درک دقیق فضای سه‌بعدی دارند بسیار مناسب است [۱۱].

۱.۳.۱ تأثیر بر حوزه‌های Imitation Learning و Grasping و نحوه انتخاب بهترین ماتریس چرخش برای گرفتن شی

مهم‌ترین کاربرد SE(3)-Transformer در رباتیک، کمک به ربات‌ها برای درک محیط سه‌بعدی و انتخاب بهترین حرکت برای تعامل با اشیاء است. این موضوع به‌ویژه در دو حوزه Imitation Learning و Grasping اهمیت زیادی دارد. در اولین مرحله، ربات باید بتواند محیط اطراف خود را از طریق دوربین مشاهده کند. معمولاً از دوربین‌هایی عمق‌سنج استفاده می‌شود که علاوه بر تصویر رنگی، فاصله‌ی هر نقطه از دوربین را نیز اندازه‌گیری می‌کنند. خروجی این دوربین‌ها به صورت یک ابر نقاط Point Cloud سه‌بعدی است که شکل واقعی اجسام را در فضا توصیف می‌کند. SE(3)-Transformer این ابر نقاط را دریافت می‌کند و با استفاده از Attention، روابط فضایی میان نقاط مختلف را تحلیل می‌کند. به عنوان مثال، اگر جسمی مانند یک لیوان روی میز قرار داشته باشد، مدل می‌تواند تشخیص دهد که کدام نقاط مربوط به بدنه‌ی لیوان و کدام نقاط مربوط به دسته‌ی آن هستند. این درک ساختاری به ربات کمک می‌کند محل مناسب برای گرفتن جسم را پیدا کند. ویژگی مهم دیگر این مدل این است که اگر همان لیوان بچرخد یا در مکان دیگری قرار گیرد، شبکه همچنان می‌تواند آن را به درستی تشخیص دهد. این موضوع برای ربات‌های صنعتی که باید با اجسام در موقعیت‌های مختلف کار کنند، بسیار حیاتی است. در حوزه Imitation Learning، ربات از رفتار انسان یاد می‌گیرد. برای مثال، یک جراح انسانی ابزار جراحی را در دست می‌گیرد و حرکتی خاص انجام می‌دهد یا یک اپراتور صنعتی قطعه‌ای را از روی میز برمی‌دارد و ربات با مشاهده‌ی این حرکات و تحلیل هم‌زمان تصویر سه‌بعدی محیط، تلاش می‌کند همان رفتار را بازتولید کند. ورودی مدل در این حالت می‌تواند شامل اطلاعات زیر باشد:

$$Input = PointCloud, RobotState, Demonstration$$

یعنی مدل هم‌زمان شکل سه‌بعدی محیط، وضعیت فعلی ربات و نمونه‌ی حرکت انسانی را دریافت می‌کند. سپس با تحلیل این اطلاعات، تصمیم می‌گیرد که ربات چگونه باید حرکت کند. خروجی شبکه معمولاً شامل دو بخش مهم است:

$$Output = (R, t)$$

که در آن R ماتریس چرخش و t بردار جابه‌جایی است. این دو پارامتر مشخص می‌کنند که بازوی ربات باید در چه موقعیتی قرار گیرد و با چه زاویه‌ای به جسم نزدیک شود. مدل SE(3)-Transformer چندین حالت مختلف برای گرفتن جسم را ارزیابی می‌کند و به هر حالت یک امتیاز اختصاص می‌دهد:

$$Score = f(PointCloud, R, t)$$

حالتی که بیشترین امتیاز را داشته باشد، به عنوان بهترین گزینه برای گرفتن انتخاب می‌شود [۱۱] [۱۲] [۱۳].



References

- [۱] Michael M. Bronstein et al. "Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges". In: arXiv preprint arXiv:2104.06345. (2021)
- [۲] Joan Sola, Jeremie Deray, and Dinesh Atchuthan. "A Micro Lie Theory for State Estimation in Robotics". In: arXiv preprint arXiv:1812.01537. (2018)
- [۳] Taco S. Cohen and Max Welling. "Group Equivariant Convolutional Networks". In: Proceedings of the 33rd International Conference on Machine Learning (ICML). 2016 pp. 2999-3009
- [۴] Nathaniel Thomas et al. "Tensor Field Networks: Rotation- and Translation-Equivariant Neural Networks for 3D Point Clouds". In: arXiv preprint arXiv:1802.08219. (2018)
- [۵] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. Deep Learning. MIT Press, 2016
- [۶] Christopher M. Bishop. Pattern Recognition and Machine Learning. Springer, 2006
- [۷] Risi Kondor and Shubhendu Trivedi. "On the Generalization of Equivariance and Convolution in Neural Networks to the Action of Compact Groups". In: Proceedings of the 35th International Conference on Machine Learning (ICML). 2018 pp. 2747-2755
- [۸] Fabian B. Fuchs et al. "SE(3)-Transformers: 3D Roto-Translation Equivariant Attention Networks". In: Advances in Neural Information Processing Systems (NeurIPS). 2020
- [۹] Victor Garcia Satorras, Emiel Hoogetboom, and Max Welling. "E(n) Equivariant Graph Neural Networks". In: Proceedings of the 38th International Conference on Machine Learning (ICML). 2021 pp. 9323-9332
- [۱۰] Ashish Vaswani et al. "Attention Is All You Need". In: Advances in Neural Information Processing Systems (NeurIPS). 2017
- [۱۱] Fabian B. Fuchs et al. "SE(3)-Transformers: 3D Roto-Translation Equivariant Attention Networks". In: Advances in Neural Information Processing Systems (NeurIPS). 2020
- [۱۲] Sergey Levine et al. "Learning Hand-Eye Coordination for Robotic Grasping with Deep Learning and Large-Scale Data Collection". In: International Symposium on Experimental Robotics. 2016
- [۱۳] Bruno Siciliano et al. Robotics: Modelling, Planning and Control. Springer, 2009